

Überblick des Experiments 1 – Ausführung durch Malte Grube

Dieses Experiment testet die Qualität von automatisiert-generierten Fragen durch vier Large Language Models (LLMs) und deren Fähigkeit, sich an gegebene Quellinhalte zu halten. Dabei wurde ein einheitliches Promptdesign pro Fragetyp (Multiple-Choice, Open-Ended) verwendet, mit dem die Modelle Fragen zum ISO-OSI-Modell generieren sollten. Details zum Prompt werden aufgrund des Blindtests nicht gegeben.

Experimentaufbau

Eingabequelle: Extrahierte Textauszüge aus Prof. Caps Vorlesungs-PDF “Referenzarchitekturen” zum ISO-OSI-Modell

Material-Aufbereitung:

- Aufteilung in 7 einzelne TXT-Files (Layer 1-7)
- Bei Fragengenerierung wurde zum schnellen Nachvollziehen nachträglich der jeweilige Layer-Text in das Frage-File geschrieben

Wertigkeit der Fragen:

In jede Frage wurde ein bestimmtes Lernziel integriert, basierend auf dem jeweiligen OSI-Layer (1/7), welches durch die Frage zu erfüllen ist. Das Einhalten dessen soll mit der **Wertigkeit**-Kategorie in der Rubrik bewertet werden. Dies wurde eingebunden, da die Wertigkeit einer Frage ein wichtiger Aspekt der Fragequalität ist, jedoch nicht über eine Zahl allein abgebildet werden kann.

Anleitung für Experten

Schritt 1: Bewertungskriterien verstehen

Lesen Sie die Rubrik exp1_rubric.md, die folgende Kategorien umfasst (jeweils 1-5 Punkte). Bestimmte Kategorien fokussieren sich auf die Bewertung der Fragen selbst, andere auf die Bewertung der Antworten. Beide Bestandteile sollen unmittelbar nach dem Lesen des jeweiligen Teils bewertet werden.

Fragenbewertung:

- **Relevanz:** Bezug zum Thema des Textinhalts
- **Klarheit:** Eindeutigkeit der Formulierung
- **Beantwortbarkeit:** Verfügbarkeit der Informationen im Text
- **Herausforderung:** Anspruchsniveau der Frage
- **Wertigkeit:** Bedeutung für vorgegebenes Lernziel
- **Sprachqualität:** Verständlichkeit und Angemessenheit

Antwortbewertung:

- **Klarheit:** Eindeutigkeit der Formulierung
- **Sprachqualität:** Verständlichkeit und Angemessenheit
- **Korrektheit:** Fachliche Richtigkeit bezogen auf den Text, gemessen als Inhaltstreue zur Quelle

Schritt 2: CSV-Struktur verstehen

Die Datei exp1.csv enthält:

- sample_id: Eindeutige ID (001-024) für Zuordnung zur Fragendatei
- layer: OSI-Layer (1-7), aus dem die Frage generiert wurde
- question_type: mcq oder open_ended
- Die 6 Bewertungsspalten für die Fragenbewertung (q_relevance, q_clarity, q_answerability, q_challenge, q_value, q_language)
- Die 3 Bewertungsspalten für die Antwortenbewertung (a_clarity, a_language, a_correctness)
- answer_problems: Sind gewisse Antworten problematisch? Warum?
- comments: Für zusätzliche Anmerkungen

Schritt 3: Bewertung durchführen

1. Öffnen Sie exp1.csv
2. Für jede Zeile:
 - Öffnen Sie die entsprechende Fragendatei und schauen Sie sich das Lernziel für diese Frage an
 - Lesen Sie die Frage sorgfältig. Lassen Sie dabei die Antwort noch außer Acht
 - Prüfen Sie den Quelltext am unteren Ende der Datei
 - Bewerten Sie nach den 6 Kategorien der Rubrik für die Frage und notieren Sie Ihre Bewertungen in die CSV
 - Lesen Sie nun die Antwort(en) zur Frage sorgfältig durch
 - Bewerten Sie nach den 3 Kategorien der Rubrik für die Antwort(en) und notieren Sie Ihre Bewertungen in die CSV
 - Notieren Sie gegebenenfalls problematische Antworten/Antwortoptionen in answer_problems, und warum diese problematisch sind
 - Ergänzen Sie bei Bedarf weitere Kommentare in comments

Vielen Dank für Ihre Unterstützung bei der Evaluation! Ihre Einschätzungen sind wertvoll für die Forschung.

Bewertungsrubrik für LLM-generierte Fragen

Relevanz/Relevance

Fragestellung: Wie gut bezieht sich die Frage aus Dozierendenperspektive auf zentrale Fachkonzepte, Themen und Fachbegriffe des bereitgestellten Textes?

Hinweis: Hier geht es nicht darum, ob der Inhalt korrekt abgebildet wird, sondern nur um den thematischen Bezug.

- **5 - Überaus relevant:** Bezieht sich auf zentrale Themen und korrekte Fachbegriffe
 - Bsp.: “Welche Kernaufgaben erfüllt der Data Link Layer und worin unterscheiden sich diese hinsichtlich ihrer Zielsetzung?”
- **4 - Relevant:** Bezieht sich auf wichtige Fachkonzepte des Textes
- **3 - Mäßig relevant:** Behandelt eher nebensächliche Aspekte oder Randthemen des Textes
- **2 - Weniger relevant:** Nur oberflächlicher Bezug zu Fachkonzepten
- **1 - Nicht relevant:** Kein Bezug zu den im Text behandelten Fachkonzepten
 - Bsp.: “Welche Programmiersprache wird am häufigsten für die Implementierung von Netzwerkprotokollen verwendet?”

Klarheit/Clarity

Fragestellung: Wie präzise und inhaltlich eindeutig ist die Frage aus Dozierendenperspektive formuliert? Bewerten Sie auch die inhaltliche Klarheit im Nachhinein für die Beantwortung der Frage.

Hinweis: Hier geht es um inhaltliche Verständlichkeit und Eindeutigkeit, nicht um sprachliche Formulierungen.

- **5 - Sehr klar:** Inhaltlich präzise und eindeutig formuliert, keine Mehrdeutigkeiten
 - Bsp.: “Nennen Sie die Kernaufgaben des Session Layer und erläutern Sie jeweils deren Funktion.”
- **4 - Klar:** Inhaltlich verständlich mit minimalen Unklarheiten
- **3 - Mäßig klar:** Enthält einige inhaltlich unklare Formulierungen
- **2 - Unklar:** Enthält mehrere mehrdeutige oder verwirrende inhaltliche Elemente
- **1 - Sehr unklar:** Inhaltlich unverständlich, Intention der Frage nicht erkennbar
 - Bsp.: “Inwiefern spielt die Schicht eine Rolle bei dem, was passiert, wenn Kommunikation stattfindet?”

Beantwortbarkeit/Answerability

Fragestellung: Hat man aus der Studierendenperspektive ausreichend Informationen im bereitgestellten Text, um die Frage vollständig zu beantworten?

Hinweis: Hier geht es nicht um die Schwierigkeit der Frage, sondern nur um die Verfügbarkeit der benötigten Informationen.

- **5 - Vollständig beantwortbar:** Alle Infos explizit im Text verfügbar
 - Bsp: "Welche Kernaufgaben hat der Presentation Layer?"
- **4 - Gut beantwortbar:** Die meisten Infos im Text
- **3 - Teilweise beantwortbar:** Grundinfos vorhanden
- **2 - Schwer beantwortbar:** Wenige Infos zur Beantwortung vorhanden
- **1 - Nicht beantwortbar:** Benötigte Informationen fehlen
 - Bsp.: "Vergleichen Sie die Effizienz des ISO-OSI-Modells mit modernen Software-Defined-Networking-Ansätzen."

Herausforderung/Challenging

Fragestellung: Wie viel kognitive Anstrengung erfordert die Beantwortung der Frage aus Studierendenperspektive?

Hinweis: Nicht die Bloom-Taxonomie als Grundlage nehmen, sondern die tatsächlich benötigte kognitive Last einschätzen.

- **5 - Sehr herausfordernd:** Erfordert mehrfaches Lesen des gesamten Textes und Verknüpfung vieler Informationen
 - Bsp.: "Analysieren Sie, warum Flusssteuerung auf mehreren OSI-Schichten implementiert wird, und bewerten Sie die Notwendigkeit dieser Redundanz."
- **4 - Herausfordernd:** Erfordert Zusammenführen von Informationen aus verschiedenen Textabschnitten
- **3 - Mäßig herausfordernd:** Erfordert Nachdenken und eigenes Formulieren, nicht nur Ablesen
- **2 - Wenig herausfordernd:** Erfordert gezieltes Suchen und Wiedergeben einer Textstelle
- **1 - Nicht herausfordernd:** Antwort kann direkt abgelesen oder mit einem Wort beantwortet werden
 - Bsp.: "Wie viele Kernaufgaben hat der Physical Layer?"

Wertigkeit/Value bzgl. Lernzielintegration

Fragestellung: Wie zentral ist das in der Frage behandelte Fachkonzept für das angestrebte Lernziel des Moduls? Nehmen Sie bei der Bewertung die Perspektive der Dozierenden ein.

Hinweis: Diese Kategorie bewertet, wie gut die Frage dazu beiträgt, das beschriebene Lernziel des Moduls zu erreichen.

- **5 - Sehr Hoch:** Behandelt Kernkonzept und zentrales Lernziel (hochrelevant)
 - Bsp.: “Erklären Sie das Zusammenspiel von Codierung, Transport und Decodierung bei der Übertragung logischer Werte auf physikalischer Ebene.”
- **4 - Hoch:** Behandelt grundlegendes Konzept zum Lernziel
- **3 - Mäßig:** Behandelt Grundlagen, die aber nicht direkt zum Lernziel passen (oder gehen darüber hinaus)
- **2 - Gering:** Fokussiert auf nebensächliches Detail oder ist ineffizient für das Lernziel
- **1 - Nicht vorhanden:** Passt gar nicht zum Lernziel
 - Bsp.: “Nennen Sie ein Beispiel für ein Kabel, das zur Datenübertragung verwendet werden kann.”

Sprachqualität/Language

Fragestellung: Wie angemessen ist aus Dozierendenperspektive die sprachliche Formulierung hinsichtlich Grammatik und Verständlichkeit? Bewerten Sie auch die sprachliche Präzision im Nachhinein für die Beantwortung der Frage.

Hinweis: Hier geht es ausschließlich um die sprachliche Form und Präzision, nicht um den Inhalt.

- **5 - Ausgezeichnet:** Präzise, angemessen, gut verständlich
 - Bsp.: “Ermitteln Sie, welche OSI-Schicht für das Setzen von Synchronisationspunkten verantwortlich ist, und erläutern Sie deren Zweck.”
- **4 - Gut:** Verständlich mit kleinen Schwächen
- **3 - Befriedigend:** Umständlich oder unpräzise
- **2 - Mangelhaft:** Schwerfällig, weitschweifig oder unnötig komplex
- **1 - Ungenügend:** Gar nicht verständlich
 - Bsp.: “Im Kontext der vielschichtigen und diversen Betrachtungsweise der Aufgabenbereiche, die dem Physical Layer im Rahmen des OSI-Referenzmodells zugeschrieben werden können, erläutern Sie diese unter Berücksichtigung relevanter Aspekte.”

Korrektheit/Correctness

Fragestellung: Wie korrekt ist die generierte Antwort auf Basis des Textinhalts?

Nehmen Sie bei der Bewertung die Perspektive der Dozierenden ein.

Hinweis: Diese Kategorie bewertet die Passung der Antwort zu Textinhalt und Frage.

- **5 - Vollständig korrekt:** Antwort entspricht vollständig dem Textinhalt
 - Bsp.: “Beschreiben Sie, wie der Network Layer die Kommunikation zwischen Geräten in unterschiedlichen Netzen ermöglicht.”
- **4 - Überwiegend korrekt:** Antwort überwiegend korrekt, minimale Ungenauigkeiten
- **3 - Teilweise korrekt:** Erkennbare Ungenauigkeiten oder unvollständige Wiedergabe von Fakten
- **2 - Größtenteils inkorrekt:** Mehrere Fehler oder Missverständnisse des Textinhalts
- **1 - Völlig inkorrekt:** Antwort enthält grundlegend falsche Inhalte
 - Bsp.: “Warum ist der Physical Layer für die Verschlüsselung von Daten zuständig?”

Multiple-Choice Question

Lernziel

Die Studierenden beherrschen die netzwerkübergreifende Kommunikation durch Adressierung, Routing und Flusssteuerung (End-to-End sowie Node-to-Node)

Formulierte Frage

Frage: Nennen Sie die beiden Strategien der Flusssteuerung im Network Layer.

Antwortmöglichkeiten:

- a) Adressierung (Falsch)
- b) End-to-End (Richtig)
- c) Node-to-Node (Richtig)
- d) Routing (Falsch)

Quelltext

Network Layer 3

Beschreibung

Bereitstellung einer Übertragung zwischen Geräten, die sich in unterschiedlichen Netzwerken (möglicherweise) verschiedener Layer 2 Technologien befinden.

3 Kernaufgaben

Adressierung:

Netzwerk-übergreifende Adressen.

Routing:

Auswahl der vermittelnden Zwischenknoten zur Kommunikation nicht direkt verbundenen Knoten.

Flußsteuerung:

Strategien, wenn zu schnell gesendet wird. End-to-End: Vom Sender zum weit entfernten Empfänger. Node-to-Node: Von jedem Knoten zum Nächsten.

Question-based:	-----
Relevance	
Clarity	
Answerability	
Challenging	
Value	
Language	
Comments	
-----	-----
Answer-based:	-----
Clarity	
Language	
Correctness	
Answer Problems	
Comments	

Open-Ended Question

Lernziel

Die Studierenden beherrschen die Mechanismen zur fehlergesicherten Datenübertragung, einschließlich Fehlerkontrolle, Flusskontrolle, Segmentierung, Identifikation und Medienzugriff

Formulierte Frage

Frage: Entwickeln Sie ein Konzept für einen Data Link Layer in einem sensorbasierten Netzwerk mit stark begrenzter Energie. Integrieren Sie dabei die fünf Kernaufgaben Fehlerkontrolle, Flusskontrolle, Segmentierung, Identifikation und Medienzugriff so, dass der Energieverbrauch minimiert wird.

Antwort: Das Konzept priorisiert minimale Aktivitätsdauer (Duty Cycling) und niedrigen Overhead. Fehlerkontrolle: Leichte Fehlererkennung via CRC, bei Fehlern verwerfen (keine Retransmission, falls Applikation tolerierbar). Flusskontrolle: Stop-and-Wait, um Puffer zu sparen und Senderrate anzupassen. Segmentierung: Feste, kleine Rahmen (z.B. 64 Byte) mit minimalem Header, um Übertragungszeit und Fehlerwahrscheinlichkeit gering zu halten. Identifikation: Kurze, lokale Cluster-Adressen (2 Byte) statt globaler Adressen. Medienzugriff: TDMA-basiert mit vorab zugeteilten Zeitschlitzten; Knoten schlafen außerhalb ihrer Sende-/Empfangsfenster. Dies minimiert Listening, Kollisionen und Overhead, und integriert alle Aufgaben energieeffizient. (Richtig)

Quelltext

Data Link Layer 2

Beschreibung

Bereitstellung einer fehlergesicherten Übertragung über einen möglicherweise nicht fehlergesicherten Physical Layer.

5 Kernaufgaben

Fehlerkontrolle:

Erkennen, Beheben oder Signalisieren von Übertragungsfehlern.

Flußkontrolle:

Strategien, wenn Sender für Empfänger zu schnell sendet. Bsp: Zwischenpuffern, Herunterregeln, warten lassen.

Segmentierung:

Zusammenfassen einzelner Bits zu größeren Einheiten. Universal-typisches Bsp: 8-bit Bytes.

Identifikation:

Auswahl bestimmter Sender oder Empfänger (sog. Adresse).

Medienzugriff:

Aktivieren des Physical Layer. 4 typische Aspekte: Senden, Warten, Beheben und Reservieren.

Question-based:	-----
Relevance	
Clarity	
Answerability	
Challenging	
Value	
Language	
-----	-----
Answer-based:	-----
Clarity	
Language	
Correctness	
Answer Problems	
Comments	